BUKU AJAR

METODOLOGI PENELITIAN

Riset Berbasis Data dan Data Mining untuk Informatika

Penulis :	Akhmad Khanif Zyen, S.Kom., M.Kom.
Mata Kuliah :	24TIF505 – Metodologi Penelitian
ISBN :	-

Program Studi Teknik Informatika

Fakultas Sains dan Teknologi

Universitas Islam Nahdlatul Ulama (UNISNU) Jepara

2026

BAB II LINGKUNGAN KERJA RISET DATA DAN AGENTIC AI

Kemampuan Akhir yang Diharapkan

Setelah mengikuti perkuliahan, membaca bab ini, dan menyelesaikan latihannya, mahasiswa diharapkan mampu:

1. Menyiapkan struktur folder proyek riset data yang tertib dan tertelusur.
2. Menggunakan Python, Jupyter Notebook, atau Google Colab beserta pustaka sains data dasar untuk eksplorasi awal.
3. Mengelola versi kerja riset dengan Git untuk menjamin ketertelusuran dan reproduksibilitas.
4. Memberikan konteks dan prompt yang efektif kepada asisten AI, lalu memverifikasi keluarannya secara kritis.

Kemampuan nonteknis yang ditanamkan pada bab ini adalah kedisiplinan mengelola berkas, ketelitian dokumentasi, dan sikap kritis terhadap teknologi.

2.1 Pengantar Bab

Penelitian yang baik lahir dari lingkungan kerja yang tertib. Pada riset berbasis data, lingkungan kerja bukan hanya soal kenyamanan, melainkan bagian dari integritas ilmiah: data versi mana yang dipakai, kode bagaimana yang menghasilkan angka pada tabel, dan siapa yang melakukan perubahan, semuanya harus dapat dilacak. Banyak skripsi terhambat bukan karena idenya buruk, melainkan karena penulisnya kehilangan jejak berkas: dataset tercampur antara versi mentah dan versi bersih, notebook lama tertukar dengan yang baru, dan hasil eksperimen tidak dapat diulang kembali.

Bab ini menyiapkan empat perkakas pokok. Pertama, struktur folder proyek riset data yang menjadi rumah bagi seluruh berkas penelitian. Kedua, lingkungan pemrograman Python dengan Jupyter Notebook dan Google Colab sebagai meja kerja utama. Ketiga, sistem kendali versi Git yang merekam seluruh sejarah perubahan. Keempat, pola kerja bersama agentic AI, yaitu asisten riset berbasis kecerdasan buatan yang mampu membaca berkas, menulis kode, dan menyusun draf teks. Keempatnya akan terus dipakai pada bab-bab berikutnya, sehingga berinvestasi waktu untuk menguasainya sekarang akan menghemat banyak waktu di kemudian hari.

2.2 Struktur Folder Proyek Riset Data

Struktur folder adalah kontrak internal peneliti dengan dirinya sendiri. Tidak ada standar tunggal yang mengikat, tetapi komunitas sains data telah menyepakati pola umum yang memisahkan data mentah, data olahan, notebook analisis, model, dan draf tulisan. Prinsip terpentingnya adalah data mentah bersifat abadi: sekali data mentah tersimpan, ia tidak boleh pernah diubah langsung; seluruh pembersihan dan transformasi dilakukan pada salinan yang dihasilkan oleh kode. Dengan begitu, kapan pun diperlukan, penelitian dapat diulang dari nol dengan menjalankan ulang kode pada data mentah yang sama.

Pola struktur folder yang disarankan untuk skripsi dan penelitian berbasis data ditunjukkan sebagai berikut.

```
skripsi-churn/
|-- literatur/        # PDF jurnal, catatan tinjauan pustaka
|-- data/
|   |-- raw/          # data mentah, TIDAK PERNAH diubah
|   |-- processed/    # data hasil cleaning dan transformasi
|-- notebook/         # Jupyter Notebook: EDA, eksperimen
|-- model/            # model tersimpan (.pkl), log eksperimen
|-- draft/            # draf proposal, skripsi, artikel
|-- README.md         # penjelasan proyek dan cara menjalankan
`-- .gitignore        # berkas yang dikecualikan dari Git
```

Tabel 2.1 merinci isi khas setiap folder beserta catatan penggunaannya. Penamaan berkas sebaiknya konsisten dan bermakna, misalnya 01_eda_eksplorasi.ipynb dan 02_model_naive_bayes.ipynb agar urutan kerja terbaca dari nama berkasnya sendiri.

Tabel 2.1 Isi khas folder proyek riset data

Folder	Isi Khas	Catatan Penting
literatur/	Artikel jurnal/prosiding (PDF), catatan ringkasan, tabel penelitian terdahulu	Simpan beserta DOI atau tautan sumber untuk verifikasi sitasi
data/raw/	Dataset asli dari Kaggle, UCI, data.go.id, atau hasil unduhan lain	Berkas tidak pernah diedit; catat sumber, tanggal unduh, dan lisensi
data/processed/	Data hasil pembersihan, encoding, normalisasi, dan pembagian train/test	Seluruhnya dihasilkan kode, bukan pengeditan manual
notebook/	Notebook EDA, persiapan data, pemodelan, dan evaluasi	Nomori notebook sesuai urutan proses; hapus sel keluaran yang sia-sia
model/	Berkas model tersimpan (misalnya .pkl/.joblib), hasil GridSearch, log metrik	Beri nama yang memuat tanggal atau nomor eksperimen
draft/	Draf proposal, bab skripsi, slide, artikel	Gunakan penomoran versi, misalnya bab3_v2.docx

Kebiasaan menata folder seperti ini terasa remeh, tetapi menjadi pembeda besar ketika penelitian memasuki bulan-bulan sibuk. Ketika dosen pembimbing bertanya dari mana angka akurasi 92 persen pada Bab IV skripsi berasal, peneliti yang tertib cukup membuka notebook bernomor dan data/processed yang dihasilkannya, bukan menebak-nebak di antara sepuluh salinan berkas.

2.3 Python, Jupyter Notebook, dan Google Colab

Python adalah bahasa pemrograman de facto untuk riset data. Ekosistem pustakanya menutupi hampir seluruh kebutuhan pipeline penelitian: pandas untuk manipulasi data tabular, NumPy untuk komputasi numerik, matplotlib dan seaborn untuk visualisasi, scikit-learn untuk algoritma data mining dan machine learning (Pedregosa dkk., 2011), serta pustaka lanjutan seperti TensorFlow dan PyTorch untuk deep learning (Géron, 2019). Cara instalasi yang paling praktis bagi mahasiswa adalah memasang Miniconda atau Anaconda, lalu membuat lingkungan kerja (environment) terpisah untuk setiap proyek agar versi pustaka antarproyek tidak saling bertabrakan.

Jupyter Notebook adalah antarmuka interaktif yang memadukan sel teks Markdown dan sel kode Python dalam satu dokumen yang dapat dieksekusi. Sifat ini menjadikannya laboratorium catatan digital peneliti: setiap analisis berdampingan dengan penjelasannya. Google Colab menawarkan kemudahan tambahan karena berjalan di peramban tanpa instalasi, menyediakan GPU gratis untuk pelatihan model yang lebih berat, dan tersimpan otomatis di Google Drive, sangat membantu mahasiswa dengan perangkat berspesifikasi terbatas. Kode berikut adalah contoh sel pertama yang lazim dijalankan untuk memeriksa data churn pelanggan telekomunikasi.

```
import pandas as pd

df = pd.read_csv("data/raw/telco_churn.csv")
print(df.shape)          # (7043, 21) -> 7043 baris, 21 kolom
print(df["Churn"].value_counts(normalize=True))
df.describe()            # statistik deskriptif kolom numerik
```

Perhatikan bahwa kode di atas memakai jalur relatif data/raw/telco_churn.csv sesuai struktur folder pada subbab sebelumnya. Kebiasaan kecil seperti ini menjaga notebook Anda tetap dapat dijalankan orang lain tanpa penyesuaian. Dataset Telco Customer Churn yang dipakai sebagai contoh tersedia publik di Kaggle dan akan terus dipakai sebagai contoh berjalan sepanjang buku ini.

2.4 Git untuk Ketertelusuran Riset

Git adalah sistem kendali versi yang merekam setiap perubahan berkas sebagai rangkaian titik penyimpanan (commit) yang dapat dikembali kapan pun (Chacon dan Straub, 2014). Dalam riset, Git menjawab tiga kebutuhan kritis. Pertama, ketertelusuran: Anda dapat menunjukkan kondisi kode tepat ketika sebuah hasil dihasilkan. Kedua, keberanian bereksperimen: cabang (branch) memungkinkan Anda mencoba ide baru tanpa merusak versi yang stabil. Ketiga, kolaborasi: dosen pembimbing dapat meninjau riwayat pekerjaan, dan manuskrip bersama rekan dapat disatukan tanpa saling menimpa. Perintah dasar yang sehari-hari dipakai peneliti cukup sedikit, seperti ditunjukkan berikut.

```
git init                        # mulai repositori di folder proyek
git status                      # lihat berkas yang berubah
git add notebook/01_eda.ipynb   # tandai berkas untuk disimpan
git commit -m "Tambah EDA awal churn: distribusi kelas"
git log --oneline               # riwayat singkat commit
```

```
git tag v0.1-eda                # tandai titik penting eksperimen
```

Satu hal yang wajib diwaspadai: Git bukan tempat untuk data besar. Berkas dataset berukuran puluhan megabyte ke atas membuat repositori gemuk dan lambat. Praktik yang benar adalah mengecualikan data dari Git memakai berkas .gitignore, lalu mendokumentasikan sumber data di README sehingga siapa pun dapat mengunduhnya kembali. Contoh isi .gitignore untuk proyek riset data:

```
data/raw/*.csv         # dataset besar tidak masuk Git
data/processed/
model/*.pkl            # artefak model berukuran besar
__pycache__/
.ipynb_checkpoints/
```

Kombinasi struktur folder, notebook, dan Git inilah yang memungkinkan reproduksibilitas: kemampuan mengulang seluruh analisis dan memperoleh hasil yang sama. Bab VIII akan memperluas praktik ini dengan pencatatan eksperimen yang lebih sistematis ketika pelatihan model berjalan dengan bantuan asisten AI.

2.5 Agentic AI sebagai Asisten Riset

Generasi terbaru alat kecerdasan buatan yang disebut agentic AI, seperti ZCode dan Hermes, tidak lagi sekadar menjawab pertanyaan dalam satu giliran obrolan. Ia dapat membaca isi proyek Anda, mencari berkas, menjalankan perintah, menulis dan menguji kode, lalu merevisi hasilnya sendiri. Dalam riset data, kemampuan ini berguna antara lain untuk mempercepat pembuatan kode persiapan data, menjelaskan pesan galat yang membingungkan, menyusun kerangka bab, dan meminta umpan balik awal atas tulisan. Kembali ke prinsip Bab I, seluruh kemudahan itu tidak mengubah posisinya: AI adalah asisten, peneliti adalah penanggung jawab.

Kunci pertama memanfaatkan asisten AI adalah memberi konteks yang memadai. Agent tidak tahu apa-apa tentang penelitian Anda kecuali Anda memberitahunya. Konteks minimal yang sebaiknya disertakan meliputi: tujuan penelitian dan pertanyaan penelitiannya, karakteristik dataset (nama kolom, tipe data, jumlah baris, sumber dan lisensinya), lingkungan kerja (versi Python dan pustaka, Colab atau lokal), serta batasan yang berlaku (misalnya hanya boleh memakai scikit-learn dan data/processed). Jangan pernah membagikan data pribadi sensitif kepada layanan AI; berikan skema atau sampel yang telah dianonimkan.

Kunci kedua adalah pola prompt yang terstruktur. Prompt riset yang baik memuat peran, konteks, tugas, batasan, format keluaran, dan kriteria verifikasi. Tabel 2.2 merangkum keenam komponen tersebut.

Tabel 2.2 Komponen prompt riset untuk agentic AI

Komponen	Pertanyaan Pemandu	Contoh Singkat
Peran	AI diminta berperan sebagai apa?	“Berperan sebagai dosen pembimbing sains data”

Komponen	Pertanyaan Pemandu	Contoh Singkat
Konteks	Fakta apa yang perlu AI ketahui?	"Dataset churn 7043 baris, kolom Churn sebagai label, 26,5% kelas positif"
Tugas	Apa yang harus dikerjakan?	"Buat notebook EDA untuk memeriksa nilai hilang dan korelasi"
Batasan	Aturan apa yang tidak boleh dilanggar?	"Hanya scikit-learn 1.5; jangan menyentuh data/raw"
Format keluaran	Bentuk hasil seperti apa yang diharapkan?	"Jelaskan per sel dengan teks Markdown dan satu tabel ringkasan"
Kriteria verifikasi	Bagaimana hasil diperiksa benar?	"Tampilkan jumlah baris sebelum-sesudah; buat asersi otomatis"

Bandingkan dua gaya meminta berikut. Prompt "buatkan kode klasifikasi churn" memberi ruang terlalu luas sehingga hasilnya jarang tepat sasaran. Prompt yang baik justru panjang dan spesifik: "Berperan sebagai peneliti sains data. Saya membandingkan Naive Bayes dan Random Forest pada data/telco_churn_processed.csv (7043 baris, label Churn). Buat kode scikit-learn versi 1.5 dengan train_test_split stratified 80:20 dan random_state 42, tampilkan accuracy, precision, recall, dan F1 untuk kedua model, sertakan komentar bahasa Indonesia di setiap langkah, dan akhiri dengan asersi yang memeriksa jumlah baris data uji." Prompt kedua secara langsung memuat konteks, tugas, batasan, format, dan kriteria verifikasi.

Kunci ketiga adalah verifikasi keluaran AI. Setiap hasil pekerjaan agent wajib melewati pemeriksaan yang sama ketatnya seperti pekerjaan mahasiswa lain. Verifikasi kode dilakukan dengan menjalankannya pada data nyata dan memeriksa keluarannya, bukan hanya membacanya. Verifikasi pernyataan faktual dilakukan dengan menelusuri sumber primer; jika AI menyebut "penelitian X mencapai akurasi 97 persen", buka artikelnya sendiri. Verifikasi draf tulisan dilakukan dengan memarafrasakan ulang dan menyesuaikan dengan gaya bahasa Anda. Kebiasaan paling berbahaya adalah menerima keluaran yang terlihat meyakinkan tanpa diperiksa; kesalahan halus pada pemisahan data uji atau sitasi fiktif justru sering tidak terlihat pada pembacaan sekilas, dan barulah ditemukan saat sidang.

2.6 Rangkuman

Bab ini menyiapkan ruang kerja riset berbasis data. Poin-poin kuncinya adalah sebagai berikut.

- Struktur folder proyek (literatur/, data/raw, data/processed, notebook/, model/, draft/) menjaga ketertiban dan ketertelusuran; data mentah tidak pernah diedit langsung.

- Python dengan pandas, NumPy, matplotlib, dan scikit-learn adalah perangkat standar; Jupyter Notebook dan Google Colab menjadi meja kerja interaktif.
- Git merekam sejarah perubahan sebagai commit dan tag; data besar dikecualikan lewat .gitignore dan didokumentasikan sumbernya di README.
- Agentic AI bekerja efektif bila diberi konteks lengkap dan prompt terstruktur (peran, konteks, tugas, batasan, format, kriteria verifikasi).
- Seluruh keluaran AI wajib diverifikasi: kode dijalankan dan diuji, fakta ditelusuri ke sumber primer, draf ditulis ulang dengan pemahaman sendiri.

2.7 Bahan Diskusi

Diskusikan topik berikut bersama rekan sekelas. Boleh saja Anda langsung mencobanya pada lingkungan kerja masing-masing agar diskusi berbantuan bukti, bukan opini.

1. Mengapa data mentah dilarang diedit langsung, dan apa akibatnya bagi reproduksibilitas bila larangan itu dilanggar? Berikan contoh kejadian yang realistis.
2. Kapan sebaiknya peneliti memilih Google Colab dan kapan sebaiknya memilih instalasi Python lokal? Pertimbangkan ukuran data, kebutuhan GPU, dan kerahasiaan data.
3. Bahas contoh prompt yang baik pada subbab 2.5. Komponen mana yang paling sering terlupa ketika mahasiswa meminta bantuan AI, dan apa dampaknya pada kualitas keluaran?
4. Kode yang dihasilkan AI tampak benar dan berjalan tanpa galat. Bukankah itu sudah cukup? Diskusikan jenis kesalahan apa yang mungkin lolos dari “kode berjalan sukses”, khususnya pada pembagian data latih-uji.

2.8 Rujukan Bab

Chacon, S., & Straub, B. (2014). Pro Git (2nd ed.). Apress.

Géron, A. (2019). Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow (2nd ed.). O'Reilly Media.

Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python. O'Reilly Media.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., … Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

UNESCO. (2023). Guidance for generative AI in education and research. UNESCO.

2.9 Latihan Soal

Kerjakan soal berikut. Soal 1 sampai 3 bersifat praktik dan sebaiknya dikerjakan langsung pada komputer Anda.

1. Praktik: buat folder proyek riset sesuai struktur pada subbab 2.2, inisialisasi Git, dan buatlah .gitignore yang mengecualikan folder data. Tangkap layar hasil git log sebagai bukti.

2. Praktik: unduh satu dataset publik apa pun dari UCI Machine Learning Repository, simpan ke data/raw, lalu tuliskan satu paragraf dokumentasi yang memuat nama dataset, sumber, tanggal unduh, jumlah baris-kolom, dan lisensinya.
3. Praktik: buka Google Colab, muat dataset dari soal 2 ke pandas, dan tampilkan lima baris pertama beserta tipe data setiap kolom.
4. Jelaskan perbedaan antara folder data/raw dan data/processed, serta mengapa isi data/processed wajib dihasilkan oleh kode.
5. Rancanglah satu prompt riset lengkap dengan enam komponen pada Tabel 2.2 untuk tugas: membuat notebook persiapan data dari dataset pemasaran bank (Bank Marketing, UCI) dengan scikit-learn.
6. Studi kasus: rekan Anda meminta AI menulis seluruh bab dua skripsi semalam, lalu mengumpulkannya tanpa membaca. Identifikasi minimal tiga risiko yang dihadapinya dari sisi integritas akademik, kualitas ilmiah, dan kesiapan sidang, serta usulkan pola kerja yang benar.