BUKU AJAR

METODOLOGI PENELITIAN

Riset Berbasis Data dan Data Mining untuk Informatika

Penulis :	Akhmad Khanif Zyen, S.Kom., M.Kom.
Mata Kuliah :	24TIF505 – Metodologi Penelitian
ISBN :	-

Program Studi Teknik Informatika

Fakultas Sains dan Teknologi

Universitas Islam Nahdlatul Ulama (UNISNU) Jepara

2026

BAB III IDENTIFIKASI MASALAH DAN STUDI LITERATUR

Kemampuan Akhir yang Diharapkan

Setelah mengikuti perkuliahan, membaca bab ini, dan menyelesaikan latihannya, mahasiswa diharapkan mampu:

1. Mengidentifikasi ide dan masalah penelitian berbasis data dari sumber open data, repositori dataset, dan kasus nyata di lingkungan sekitar.
2. Menelusuri literatur ilmiah secara efektif melalui Google Scholar, Sinta, Garuda, dan basis data internasional.
3. Mengelola referensi dengan Zotero atau Mendeley dan menyusun tabel penelitian terdahulu yang informatif.
4. Memverifikasi sitasi serta mendeteksi halusinasi yang mungkin dihasilkan asisten AI.

Kemampuan nonteknis yang ditanamkan pada bab ini adalah rasa ingin tahu, ketelitian dalam verifikasi sumber, dan kejujuran dalam mencantumkan rujukan.

3.1 Pengantar Bab

Kualitas sebuah penelitian sangat ditentukan sejak tahap paling awal: pemilihan masalah. Masalah yang terlalu luas membuat penelitian tak pernah selesai; masalah yang terlalu sempit membuat kontribusinya tidak berarti; masalah yang datanya tidak tersedia membuat seluruh rancangan runtuh di tengah jalan. Pada riset berbasis data, pemilihan masalah selalu berpasangan dengan ketersediaan data: pertanyaan yang menarik tetapi tanpa data hanyalah wacana. Oleh karena itu, bab ini mengajarkan dua kegiatan yang berjalan saling silang, yaitu mengidentifikasi masalah dan menelusuri literatur.

Studi literatur dalam riset data punya fungsi yang sangat konkret. Ia menunjukkan algoritma dan metrik apa yang lazim dipakai untuk masalah serupa, memberi tolok ukur (baseline) yang hasilnya nantinya Anda bandingkan, dan menyingkap celah penelitian (research gap) yang menjadi justifikasi kebaruan skripsi Anda. Di ujung proses, literatur yang tertata rapi akan menjadi kerangka bab tinjauan pustaka. Bab ini juga membahas cara bekerja bersama asisten AI pada tahap ini secara aman, termasuk cara mendeteksi referensi fiktif yang kerap dihalusinasi oleh model bahasa.

3.2 Sumber Ide Penelitian Berbasis Data

Ide penelitian berbasis data dapat muncul dari tiga arah. Pertama, masalah nyata di lingkungan sekitar: kampus, rumah tangga, industri, dan pemerintahan. Lingkungan sekitar kampus di Jepara kaya bahan riset, misalnya pola penjualan industri mebel, hasil tangkapan dan harga ikan di pelabuhan perikanan, tingkat hunian hotel akibat kunjungan wisata, atau keberhasilan studi mahasiswa berdasarkan riwayat akademik. Masalah-masalah seperti ini relevan dengan prinsip buku ajar yang menyarankan konteks regional, dan biasanya mudah dipertahankan urgensinya di hadapan penguji.

Kedua, data publik yang telah tersedia. Ribuan dataset terbuka menunggu diteliti, mulai dari data statistik pemerintah hingga dataset kompetisi machine learning. Ketiga, literatur ilmiah itu sendiri: membaca lima artikel sejenis akan memunculkan pertanyaan lanjutan, misalnya pengulangan penelitian dengan algoritma berbeda, dataset berbeda, atau penambahan tahap seleksi fitur. Arah ketiga ini yang lazim disebut penelitian replikasi-perluasan, dan merupakan jalur terselamat bagi mahasiswa yang bingung mencari ide.

Sebuah ide layak maju menjadi penelitian bila lolos tiga saringan sederhana. Saringan pertama adalah ketersediaan data: apakah data benar-benar dapat diperoleh secara legal? Saringan kedua adalah kebermaknaan: apakah jawabannya bermanfaat bagi pihak tertentu? Saringan ketiga adalah kelayakan teknis: apakah ukuran data, komputasi, dan waktu yang tersedia (umumnya satu semester) memadai? Ide yang lolos ketiganya biasanya menghasilkan rumusan masalah yang sehat, yang akan dirumuskan formal pada Bab IV.

3.3 Repositori Dataset Publik

Bagi mahasiswa, repositori dataset publik adalah pintu masuk paling praktis. Kaggle menyediakan ribuan dataset dengan lisensi yang dicantumkan jelas, dilengkapi notebook komunitas yang dapat dipelajari, dan kompetisi untuk menguji kemampuan. UCI Machine Learning Repository adalah repositori klasik yang menjadi rujukan utama dalam ribuan artikel ilmiah, sehingga dataset dari UCI memudahkan perbandingan hasil dengan penelitian terdahulu. Untuk data Indonesia, portal data.go.id mengumpulkan dataset terbuka dari instansi pemerintah, meski kualitas dan kelengkapannya bervariasi. Tabel 3.1 merangkum beberapa dataset populer yang nyata dan sering dipakai dalam penelitian data mining.

Tabel 3.1 Contoh dataset publik populer untuk riset data mining

Dataset	Sumber	Skala Data	Tipe Tugas Khas
Iris	UCI	150 baris, 4 fitur	Klasifikasi multikelas spesies bunga
Heart Disease (Cleveland)	UCI	303 baris, 13 fitur	Klasifikasi biner diagnosa penyakit jantung
Bank Marketing	UCI	45.211 baris, 16 fitur	Klasifikasi biner keberhasilan telemarketing
Adult Income	UCI	48.842 baris, 14 fitur	Klasifikasi biner pendapatan di atas 50K
Online Retail	UCI	541.909 transaksi	Analisis asosiasi dan segmentasi pelanggan
Wine Quality	UCI	6.497 baris, 11 fitur	Regresi/klasifikasi kualitas anggur

Dataset	Sumber	Skala Data	Tipe Tugas Khas
Telco Customer Churn	Kaggle	7.043 baris, 21 kolom	Klasifikasi biner pelanggan berhenti berlangganan

Dua kebiasaan penting saat memilih dataset. Pertama, catat dan kutip sumbernya secara resmi: nama repositori, tautan, tanggal unduh, dan lisensinya. Lisensi menentukan boleh tidaknya data dipakai, didistribusikan ulang, atau dipublikasikan hasil olahannya. Kedua, periksa keseimbangan kelas dan kelengkapan data sejak awal; dataset dengan kelas target timpang berat (misalnya 5 persen pelanggan churn) menuntut perlakuan khusus pada tahap persiapan data yang dibahas di Bab VI.

3.4 Penelusuran Literatur Ilmiah

Literatur ilmiah hari ini tersedia lebih terbuka daripada sebelumnya. Google Scholar adalah mesin pencari lintas penerbit yang paling sering dipakai; fitur “Dikutip oleh” (cited by) membantu melacak perkembangan sebuah ide, sedangkan tautan PDF di sisi kanan hasil pencarian sering mengarah ke versi gratis. Untuk konteks Indonesia, Sinta mengindeks jurnal nasional terakreditasi dan Garuda menyediakan portal agregasi jurnal Indonesia; keduanya wajib dikonsultasikan agar tinjauan pustaka mencerminkan riset dalam negeri. Untuk publikasi internasional informatika, IEEE Xplore dan ACM Digital Library adalah basis data utama, sementara arXiv memuat pracetak terbaru bidang machine learning.

Strategi penelusuran yang efektif menuntut kemampuan merumuskan kata kunci. Gunakan kombinasi kata kunci terbatas dan operator Boolean: tanda kutip untuk frasa, misalnya “data mining”, AND untuk mempersempit, dan OR untuk sinonim. Contoh: (“customer churn” OR “churn prediction”) AND (“random forest”) AND (telecom). Selain itu, manfaatkan filter tahun (umumnya 5–10 tahun terakhir agar referensi mutakhir) dan teknik snowballing, yaitu menelusuri daftar pustaka dari artikel yang sudah didapat untuk menemukan artikel lain yang relevan, baik ke belakang (rujukan yang dikutip) maupun ke depan (artikel yang mengutipnya).

Batas waktu dan jumlah tidak ada yang mutakhir, tetapi pengalaman umum menunjukkan 15 sampai 30 artikel relevan sudah cukup membumi bagi skripsi sarjana, dengan catatan sebagian besar adalah artikel jurnal primer, bukan blog atau slide kuliah. Pedoman buku ajar UNISNU mengingatkan bahwa pustaka sebaiknya terbit tidak lebih dari sepuluh tahun terakhir, kecuali karya klasik yang memang menjadi rujukan dasar seperti Fayyad dkk. (1996) atau Han, Kamber, dan Pei (2012).

3.5 Manajemen Referensi dengan Zotero dan Mendeley

Semakin banyak artikel dibaca, semakin besar godaan mencatat rujukan secara manual, dan semakin besar pula risiko kesalahan penulisan. Perangkat lunak manajemen referensi seperti Zotero dan Mendeley menyelesaikan masalah ini: menyimpan metadata artikel dengan satu klik dari peramban, mengelompokkannya ke dalam koleksi per penelitian, menyimpan PDF, dan menghasilkan sitasi serta daftar pustaka otomatis dengan gaya APA, IEEE, maupun lainnya.

Keduanya dapat terintegrasi dengan Microsoft Word sehingga sitasi dalam teks dan daftar pustaka diperbarui otomatis ketika ada perubahan.

Pilihan antara keduanya bebas; Zotero bersifat sumber terbuka dan sangat matang dalam menangkap metadata dari berkas PDF, sedangkan Mendeley terintegrasi erat dengan pembaca PDF dan jaringan peneliti. Yang dinilai bukan alatnya, melainkan disiplinnya: seluruh rujukan sejak hari pertama masuk ke manajer referensi, dan daftar pustaka dihasilkan alat, bukan diketik tangan. Kebiasaan ini akan sangat menyelamatkan saat tahap penulisan laporan pada Bab X, ketika puluhan rujukan harus konsisten dalam satu gaya.

3.6 Tabel Penelitian Terdahulu

Bab tinjauan pustaka pada skripsi riset data hampir selalu memuat tabel penelitian terdahulu. Tabel ini bukan hiasan; ia adalah alat analisis untuk menemukan celah penelitian. Kolom yang paling informatif untuk riset berbasis data adalah: peneliti dan tahun, dataset, algoritma, metrik evaluasi, hasil, dan celah penelitian. Dengan struktur seperti ini, pola penelitian terdahulu langsung terlihat: algoritma mana yang paling sering menang, metrik apa yang lazim, dan kombinasi apa yang belum dicoba. Tabel 3.2 memperlihatkan format tersebut dengan baris ilustratif (bukan rujukan nyata, hanya contoh cara mengisi).

Tabel 3.2 Format tabel penelitian terdahulu (baris berupa ilustrasi, bukan rujukan nyata)

Peneliti (Tahun)	Dataset	Algoritma	Metrik	Hasil	Celah
Peneliti A (2019)	Churn operator telekomunikasi (7.043 baris)	Naive Bayes vs C4.5	Accuracy, AUC	C4.5 unggul: accuracy 0,84	Belum ada SMOTE untuk kelas timpang
Peneliti B (2021)	Dataset yang sama	C4.5 + SMOTE	F1, AUC	F1 naik 0,79 menjadi 0,85	Belum ada perbandingan dengan Random Forest
Peneliti C (2023)	Dataset bank pemerintah	Random Forest	F1, AUC	F1 0,88	Tidak ada uji signifikansi antar model

Dari tabel ilustratif di atas, celah penelitian yang wajar untuk digagas adalah menerapkan Random Forest disertai SMOTE dan pengujian signifikansi pada dataset yang sama. Perhatikan bahwa celah yang baik spesifik dan dapat diuji, bukan sekadar “belum ada yang meneliti di kampus kami”. Setiap baris tabel penelitian terdahulu pada skripsi Anda nantinya wajib merujuk artikel yang benar-benar ada dan Anda baca sendiri.

3.7 Verifikasi Sitasi dan Deteksi Halusinasi AI

Model bahasa, termasuk yang berbentuk agen, kerap menghasilkan referensi yang tampak sangat meyakinkan padahal tidak pernah ada: nama penulis sungguhan dipasangkan dengan judul fiktif, tahun keliru, atau jurnalnya tidak pernah menerbitkan artikel itu. Fenomena halusinasi ini membuat penggunaan AI pada tahap studi literatur berisiko tinggi. Aturan amannya sederhana: setiap referensi yang disarankan AI berstatus terduga, bukan fakta, sampai Anda menemukan berkas aslinya.

Prosedur verifikasi yang praktis adalah sebagai berikut.

1. Salin judul artikel persis seperti yang diberikan AI dan cari di Google Scholar; jangan menerima hasil yang hanya mirip.
2. Periksa identitas sumber: DOI melalui situs crossref atau doi.org, nama jurnal di laman resminya, dan volume-halaman yang cocok.
3. Baca minimal abstrak dan bagian metode; pastikan artikel benar mengatakan hal yang Anda kutip.
4. Simpan artikel dan metadata-nya ke Zotero/Mendeley; jika tidak ditemukan sama sekali, buang referensi itu dan catat sebagai indikasi halusinasi.

Kebalikan dari halusinasi juga perlu diwaspadai: AI dapat mengutip artikel nyata tetapi dengan isi yang salah. Karena itu pemeriksaan tidak berhenti pada keberadaan artikel, melainkan sampai pada kesesuaian isi. Di samping itu, sitasi dari rekan satu angkatan atau dari artikel ilmiah populer pun tetap wajib dilacak ke sumber primernya; prinsip verifikasi ini berlaku untuk semua sumber, bukan hanya keluaran AI (Cotton, Cotton, dan Shipway, 2024).

3.8 Rangkuman

Bab ini membahas identifikasi masalah dan studi literatur dalam riset berbasis data. Poin-poin kuncinya adalah sebagai berikut.

- Ide penelitian bersumber dari masalah nyata, data publik, dan literatur; sebuah ide layak bila lolos saringan ketersediaan data, kebermaknaan, dan kelayakan teknis.
- Kaggle, UCI Machine Learning Repository, dan data.go.id adalah repositori dataset utama; sumber, tanggal unduh, dan lisensi dataset wajib dicatat.
- Penelusuran literatur memanfaatkan Google Scholar, Sinta, Garuda, IEEE Xplore, dan arXiv dengan strategi kata kunci Boolean dan snowballing.
- Zotero atau Mendeley menjaga konsistensi rujukan sejak hari pertama dan menghasilkan daftar pustaka otomatis.
- Tabel penelitian terdahulu dengan kolom dataset-algoritma-metrik-hasil-celah adalah alat menemukan research gap yang spesifik dan teruji.
- Setiap referensi dari AI berstatus terduga sampai diverifikasi ke sumber primer; halusinasi sitasi adalah risiko nyata yang wajib dicegah.

3.9 Bahan Diskusi

Diskusikan topik berikut bersama rekan sekelas, idealnya sambil membuka perangkat dan mencoba langsung strategi yang dibahas.

1. Pilih satu masalah nyata di sekitar kampus atau kota Jepara. Data apa yang dibutuhkan, dari mana memperolehnya, dan apakah lolos ketiga saringan kelayakan pada subbab 3.2?
2. Bandingkan dua dataset pada Tabel 3.1 pilihan Anda: mana yang lebih cocok untuk skripsi satu semester dan mengapa?
3. Apa bedanya celah penelitian yang spesifik dan dapat diuji dengan celah yang dangkal? Uji dengan menilai tiga contoh celah yang diusulkan teman sekelas.
4. Mengapa referensi yang dihasilkan AI harus dianggap terduga, padahal AI dapat mengutip sumber yang benar-benar ada? Kaitkan dengan cara kerja model bahasa.

3.10 Rujukan Bab

Cotton, D. R. E., Cotton, P. A., & Shipway, J. R. (2024). Chatting and cheating: Ensuring academic integrity in the era of ChatGPT. Innovations in Education and Teaching International, 61(2), 228–239.

Han, J., Kamber, M., & Pei, J. (2012). Data mining: Concepts and techniques (3rd ed.). Morgan Kaufmann.

Kelleher, J. D., Mac Namee, B., & D'Arcy, A. (2020). Fundamentals of machine learning for predictive data analytics (2nd ed.). MIT Press.

Müller, A. C., & Guido, S. (2016). Introduction to machine learning with Python. O'Reilly Media.

Tan, P.-N., Steinbach, M., & Kumar, V. (2019). Introduction to data mining (2nd ed.). Pearson.

3.11 Latihan Soal

Kerjakan soal berikut secara berurutan. Soal 1 sampai 3 bersifat praktik dan hasilnya akan dipakai kembali pada bab-bab berikutnya.

1. Praktik: pilih satu dataset dari Tabel 3.1, unduh dari repositori asalnya, dan tuliskan satu paragraf dokumentasi yang memuat sumber, lisensi, tanggal unduh, deskripsi singkat, dan hipotesis satu masalah yang dapat diteliti darinya.
2. Praktik: lakukan penelusuran di Google Scholar dengan kata kunci Boolean untuk tema churn atau diagnosa penyakit, terapkan filter 5 tahun terakhir, dan kumpulkan 10 artikel; simpan seluruhnya ke koleksi Zotero/Mendeley.
3. Praktik: susun tabel penelitian terdahulu dari 5 artikel yang dikumpulkan pada soal 2 dengan kolom dataset-algoritma-metrik-hasil-celah, lalu rumuskan satu celah penelitian yang spesifik.
4. Jelaskan tiga saringan kelayakan ide penelitian berbasis data dan berikan contoh gagasan yang gagal pada masing-masing saringan.

5. Mengapa dataset UCI sering dipilih untuk skripsi yang membandingkan algoritma? Jelaskan dengan konsep perbandingan hasil antar penelitian.
6. Studi kasus: AI memberi Anda lima referensi; tiga ditemukan persis di Google Scholar, satu ditemukan tetapi isi artikelnya berbeda dari klaim AI, dan satu tidak pernah ditemukan. Bagaimana perlakuan Anda terhadap masing-masing, dan apa yang Anda laporkan tentang penggunaan AI tersebut?